#![arian] cat ./rfc-001-vibe-coding-di-chat.md

ARCHITECTURE · RFC-001

# Vibe coding di dalam chat.

Rancangan untuk menjalankan Claude Code di container milik sendiri dan menyambungkannya ke chat service yang sudah ada — dengan streaming jawaban, izin tool di chat, notifikasi tugas, sesi yang bisa dilanjutkan, dan diagram interaktif flowmaid.

TLDR.MD

- Agent runtime: Claude Agent SDK di satu sandbox per sesi.
- Chat service tetap jadi pintu masuk; orchestrator baru di belakangnya.
- Event agen (selesai, butuh izin) lewat hook `http` ke notif service.
- Sesi tersimpan di storage service — container boleh mati, sesi tetap jalan.
- flowmaid merender diagram di chat: WASM di klien, SVG di server.

| | |
|---|---|
| STATUS | ● draft untuk review |
| PEMILIK | Arian Saputra |
| CAKUPAN | chat · agent · notif |
| RUNTIME | Claude Agent SDK |
| DIAGRAM | flowmaid dev |
| RILIS FLOWMAID | ○ 0.34.0 · menyusul |

ISI DOKUMEN — 12 BAGIAN

01 ringkasan
02 konteks
03 diagram arsitektur
04 komponen baru
05 alur utama
06 flowmaid di chat
07 keamanan
08 data & penyimpanan
09 skala & biaya
10 rencana bertahap
11 risiko
12 referensi

#![arian] cat ./01_ringkasan.md

# Ringkasan

Chat service yang sudah ada mendapat satu kemampuan baru: menerima perintah "vibe coding" dan menjalankannya lewat Claude Code di container kita sendiri. Pengguna mengetik di chat, agen bekerja di sandbox, jawaban dan progres mengalir balik ke thread yang sama.

| 1:1 | 6 | 7 | <6ms |
|---|---|---|---|
| SANDBOX PER SESI | LAYANAN YANG DIPAKAI ULANG | KOMPONEN BARU | DRAG DIAGRAM FLOWMAID |

## Apa yang dibangun

- **Session orchestrator** — memetakan thread chat ke sesi agen dan sandbox, men-stream token ke chat service.
- **Sandbox runner pool** — container siap pakai berisi Claude Agent SDK, CLI `claude` dan toolchain build.
- **Event gateway** — menerima hook `http` dari agen (selesai, butuh izin, error) dan meneruskannya ke notif service.
- **Secret vault + egress proxy** — API key dan token git disuntikkan per sesi; lalu lintas keluar lewat allowlist.
- **flowmaid** — diagram mermaid di pesan agen dirender interaktif di chat, dan dikirim balik sebagai teks setelah diedit.

## Keputusan utama

| KEPUTUSAN | PILIHAN | ALASAN |
|---|---|---|
| Runtime agen | Claude Agent SDK (TypeScript / Python) | Cara resmi meng-embed Claude Code: streaming, sesi, hook, izin, sub-agent. Untuk bahasa lain: `claude -p` stream-json. |
| Isolasi | Satu sandbox per sesi, warm pool | File, proses dan rahasia tiap pengguna terpisah; sandbox mati tidak menyeret sesi lain. |
| Event | Hook `http` → event gateway | Tanpa polling. `Stop`, `TaskCompleted`, `Notification` langsung sampai ke notif service. |
| Autentikasi | API key Claude Console / Bedrock / Vertex di vault | Wajib untuk produk yang melayani pengguna lain (Commercial Terms). Login Pro/Max tidak boleh dipakai. |
| State sesi | Event log + transkrip di storage service | Sesi bisa dilanjutkan di host lain (`resume` + `SessionStore`) setelah container diganti. |
| Diagram | flowmaid: WASM di klien, SVG di server | Zero dependency, deterministik, drag cepat, satu sumber geometri untuk layar dan ekspor. |

#![arian] cat ./02_konteks.md

# Konteks

Platform sudah punya layanan inti. Rancangan ini memakai ulang semuanya dan hanya menambah lapisan agen di belakang chat service. Tidak ada layanan lama yang diganti.

## Layanan yang sudah ada

| LAYANAN | STATUS | PERAN DALAM ARSITEKTUR INI |
|---|---|---|
| Account service | ADA | Identitas pengguna dan tenant; kuota dan batas biaya agen per akun; kepemilikan API key (kunci platform atau milik pengguna). |
| Chat service | ADA | Pintu masuk. Meneruskan prompt ke orchestrator, men-stream token ke klien, menampilkan kartu izin dan blok diagram flowmaid. |
| Notif service | ADA | Menerima event dari event gateway — tugas selesai, butuh izin, gagal — lalu mengirim push dan in-app. |
| Email service | ADA | Ringkasan tugas panjang dan laporan harian; thumbnail diagram dari flowmaid server-side. |
| Storage service | ADA | Event log dan transkrip sesi, snapshot workspace, artefak dan lampiran yang dihasilkan agen. |
| dll. | ADA | Billing / metering (biaya token per sesi), audit log, observability (OpenTelemetry). |

## Komponen baru

| KOMPONEN | STATUS | TUGAS SINGKAT |
|---|---|---|
| Session orchestrator | BARU | API sesi, peta thread ↔ sesi ↔ sandbox, stream event, kuota. |
| Sandbox runner pool | BARU | Container hangat, klaim per sesi, reclaim saat idle. |
| Agent runtime | BARU | Claude Agent SDK di dalam sandbox; menulis ke workspace git. |
| Event gateway | BARU | Penerima hook `http`; verifikasi, routing ke chat dan notif. |
| Secret vault | BARU | API key Claude dan token git, disuntikkan saat sandbox diklaim. |
| Egress proxy | BARU | Satu-satunya jalan keluar sandbox: allowlist, log, batas. |
| flowmaid render | BARU | WASM di klien untuk diagram interaktif; SVG di server untuk notif dan email. |

**PRINSIP** Agen tidak pernah bicara langsung ke klien. Semua lewat chat service, sehingga autentikasi, rate limit dan audit tetap di satu tempat.

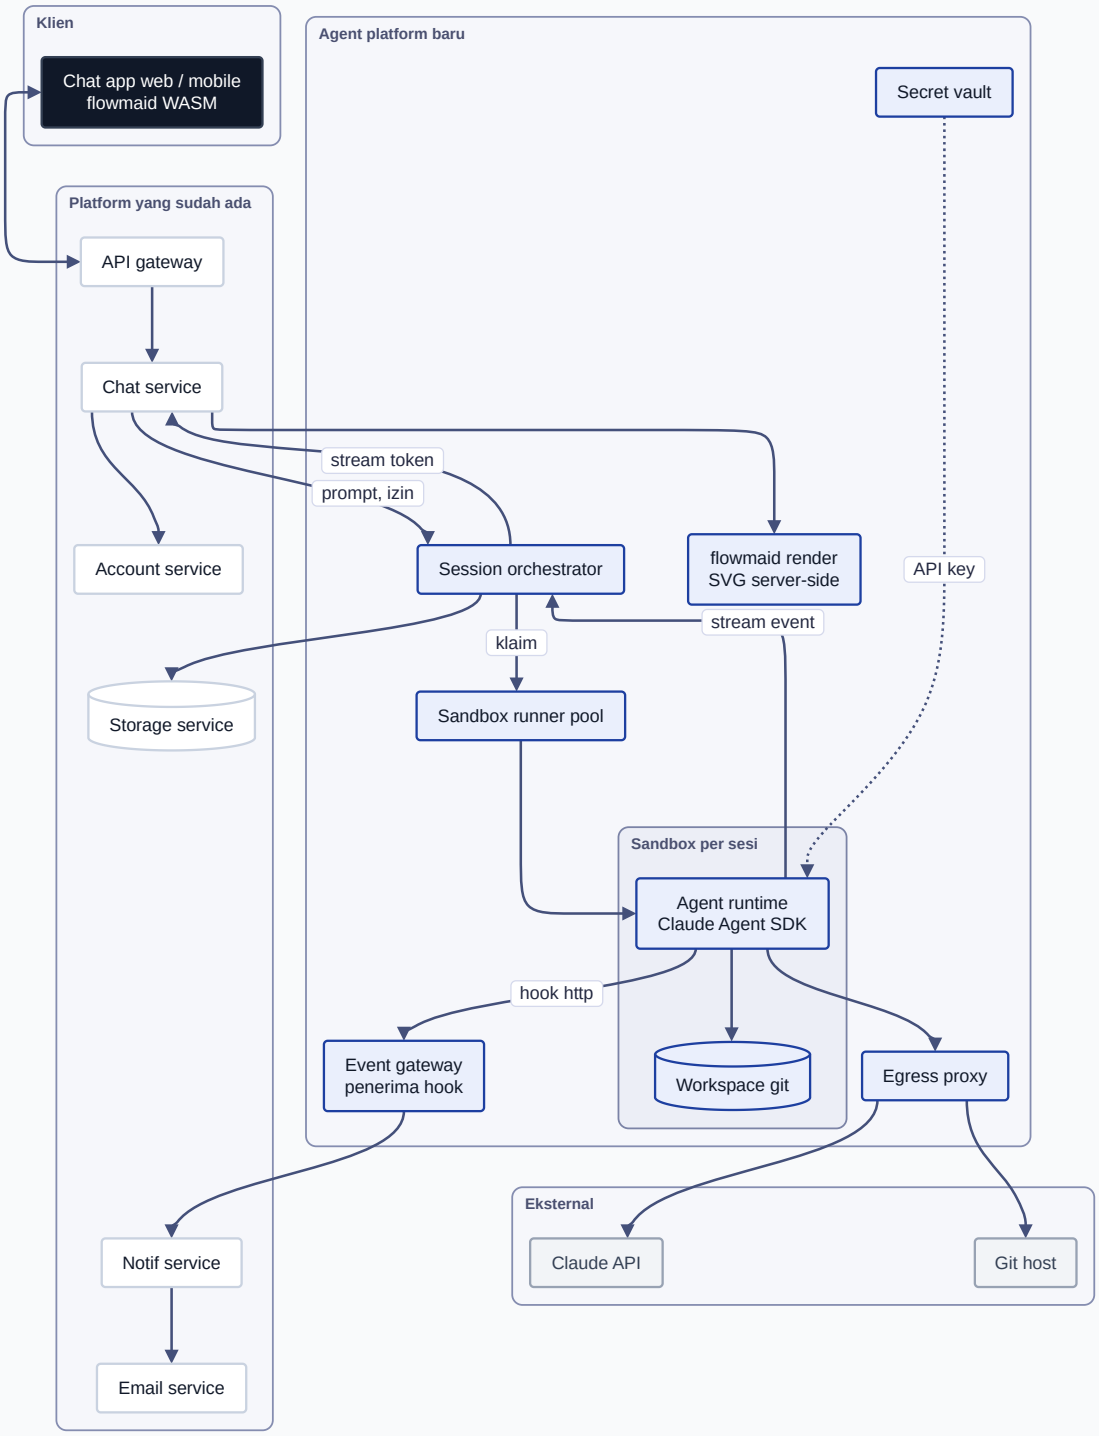
#![arian] cat ./03_diagram-arsitektur.md

# Diagram arsitektur

☐ klien ☐ layanan yang sudah ada ☐ komponen baru ☐ eksternal

⋯ garis titik = rahasia disuntikkan

ARCHITECTURE.MMD — DIRENDER DENGAN FLOWMAID




Sandbox per sesi hanya bisa keluar lewat egress proxy. Chat service tetap satu-satunya pintu ke klien.

# Komponen baru

### Session orchestrator — GO · STATELESS

- `POST /sessions`, `/sessions/{id}/messages`, `/interrupt`, `/permissions/{req}`.
- Peta `thread_id` ↔ `session_id` ↔ `sandbox_id` di Redis / Postgres.
- Stream event ke chat service lewat gRPC stream atau SSE.
- Menulis event log ke storage service; cek kuota di account service.

### Sandbox runner pool — K3S · GVISOR

- Pod hangat siap klaim; mulai dari 1 vCPU / 1 GiB per agen.
- Image: Agent SDK, CLI `claude`, git, node, go, rust.
- NetworkPolicy: keluar hanya ke egress proxy; ResourceQuota per tenant.
- Idle lewat batas → suspend; TTL habis → reclaim.

### Agent runtime — CLAUDE AGENT SDK

- `ClaudeSDKClient` / `query()` dengan `include_partial_messages`.
- `resume: session_id`; `canUseTool` meneruskan izin ke chat.
- `settingSources: []`, `cwd` per sesi, tanpa login OAuth.
- Sub-agent: pesan membawa `parent_tool_use_id`.

### Event gateway — GO · HTTP

- Menerima hook `http`: `Stop`, `SubagentStop`, `TaskCompleted`, `Notification`.
- `PostToolUse` masuk audit log.
- Token per sesi di header; event tanpa token ditolak.
- Meneruskan ke chat service (thread) dan notif service (push).

### Secret vault — VAULT / KMS

- API key Claude per tenant, token git per pengguna.
- Disuntikkan ke env sandbox saat klaim, dicabut saat reclaim.
- Tidak pernah masuk prompt, transkrip atau log.

### Egress proxy — ENVOY / SQUID

- Allowlist: `api.anthropic.com`, git host, registry paket.
- Log per sesi; batas bandwidth dan koneksi.
- Tambah domain lewat konfigurasi tenant, bukan dari agen.

### flowmaid render — RUST · WASM32 · ZERO DEPS

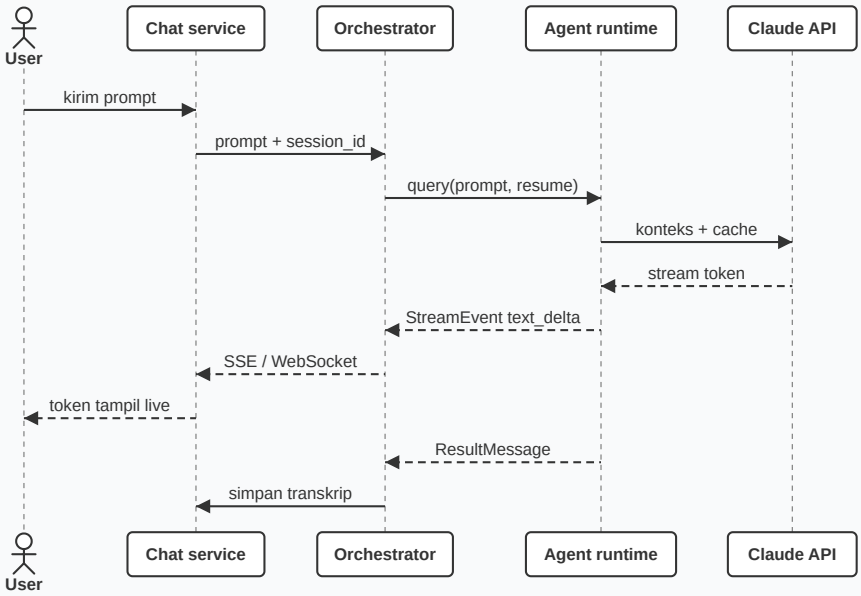
- Klien: modul WASM merender blok `mermaid` di pesan agen sebagai diagram interaktif.
- Server: library atau CLI yang sama menghasilkan SVG untuk thumbnail notif, email dan preview link.
- 13 jenis diagram: flowchart, sequence, class, state, ER, gitGraph, architecture, mindmap, dan lainnya.
- Tema mengikuti aplikasi: palet semantik flowmaid, atau `neutral` / `dark` / `forest`.

# Alur utama

## 05.1 Kirim prompt, terima jawaban live

Chat service meneruskan prompt beserta `session_id`. Orchestrator memanggil agen dengan `resume`, sehingga konteks percakapan lama ikut. Token mengalir balik sebagai `StreamEvent` dan ditampilkan langsung di thread. `ResultMessage` di akhir membawa biaya dan pemakaian token untuk metering.

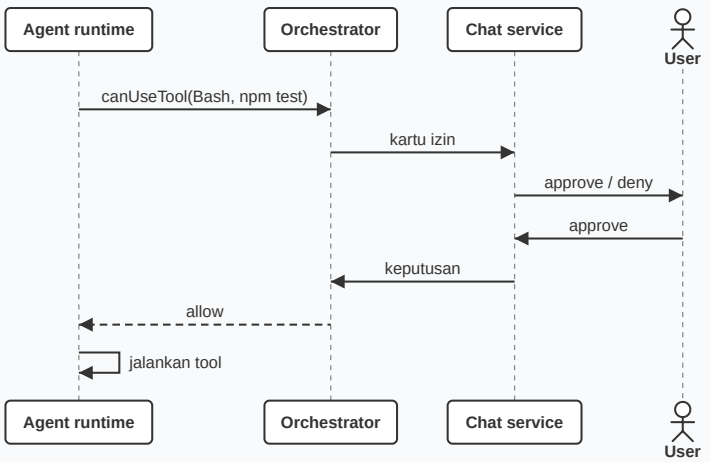
PROMPT-STREAM.MMD — SEQUENCE




## 05.2 Izin tool di dalam chat

Sebelum agen menjalankan perintah berisiko — `Bash`, menulis file di luar workspace, akses jaringan baru — SDK memanggil `canUseTool`. Orchestrator menahan giliran itu dan chat service menampilkan kartu approve / deny. Mode izin per tenant: `default`, `acceptEdits`, atau `plan` untuk review sebelum eksekusi.

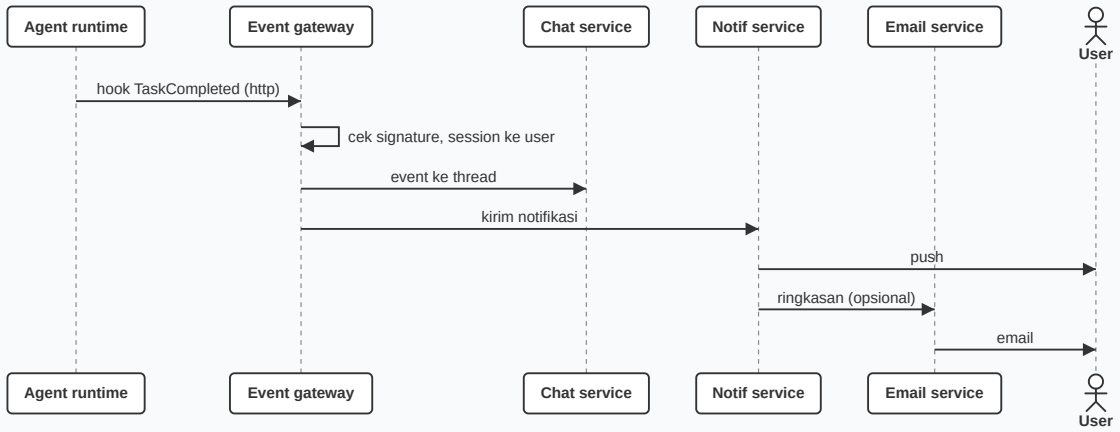
PERMISSION.MMD — SEQUENCE



## 05.3 Tugas background dan notifikasi

Tugas panjang — build, test suite, sub-agent — tetap berjalan saat pengguna menutup aplikasi. Hook `TaskCompleted` atau `Stop` mengirim JSON event ke event gateway. Gateway mencocokkan sesi ke pengguna, menaruh event di thread chat, dan meminta notif service mengirim push. Email hanya untuk ringkasan, bukan untuk setiap event.

BACKGROUND-NOTIF.MMD — SEQUENCE



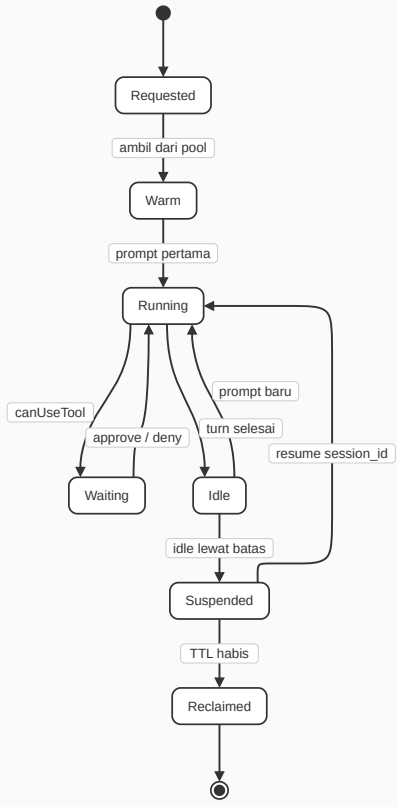

## 05.4 Siklus hidup sesi

Sesi dan sandbox punya umur yang berbeda. Sandbox boleh mati — idle terlalu lama, node di-drain, crash — tanpa kehilangan percakapan.

- **Warm**: pod sudah hidup di pool, belum terikat pengguna.
- **Running / Waiting**: agen bekerja, atau menunggu izin di chat.
- **Idle**: giliran selesai; sandbox masih terpasang untuk balasan cepat.
- **Suspended**: sandbox dilepas; event log dan snapshot workspace ada di storage service.
- **Resume**: prompt baru mengklaim sandbox baru, memulihkan workspace, lalu memanggil agen dengan `resume: session_id` lewat `SessionStore`.
- **Reclaimed**: TTL habis; data dihapus sesuai kebijakan retensi.

**CATATAN** Format file transkrip `.jsonl` milik CLI bersifat internal dan bisa berubah. Simpan event dari stream-json / SDK, jangan parse transkrip.

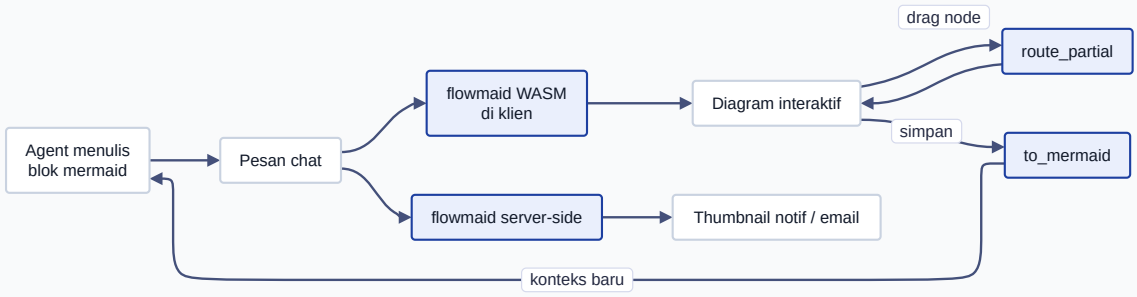
SESSION.MMD — STATE



# flowmaid di dalam chat

Vibe coding banyak bicara lewat diagram: alur API, skema data, state machine, urutan deploy. Agen menulis blok `mermaid`; chat merendernya dengan flowmaid, dan pengguna bisa langsung menggeser node. Hasil edit dikirim balik sebagai teks mermaid, jadi agen membaca diagram yang sama dengan yang dilihat pengguna.

FLOWMAID-LOOP.MMD — FLOWCHART




## Kenapa flowmaid

- Zero dependency, satu crate Rust; build ke `wasm32` tanpa runtime JS besar.
- Interaktif: `scene`, `route_partial` saat drag, `hit_test` untuk pick, `to_mermaid` untuk simpan.
- Deterministik: input sama, SVG sama — aman untuk cache dan snapshot test.
- Satu sumber geometri untuk layar, thumbnail dan ekspor SVG.
- 13 jenis diagram mermaid, tema mengikuti aplikasi.

## Garis besar integrasi

CHAT_RENDER.RS

```rust
// klien (wasm): blok mermaid agen
let g     = parse(src)?;
let scene = scene::scene(&g);
// drag: hanya edge terdampak
route_partial(&g, &scene, moved);
let hit = scene.hit_test(x, y);
// simpan: kembali ke agen
let text = to_mermaid(&g);
// server: SVG notif / email
let svg =
  render_svg_advanced(src, &opts)?;
```

Nama fungsi sesuai README flowmaid; signature lengkap di dokumentasi crate.

**STATUS** flowmaid sedang di fase B (paket 7 dari 13: label dan port). Diagram di dokumen ini dirender dengan build dev hari ini. Rilis 0.34.0 menyusul setelah fase B dan C selesai.

#![arian] cat ./07_keamanan.md

# Keamanan dan isolasi

- **Satu sandbox per sesi.** Filesystem, proses dan env tidak dibagi antar pengguna. Runtime seperti gVisor atau Kata menambah lapisan di atas container biasa.
- **Jaringan tertutup.** NetworkPolicy deny-all; keluar hanya lewat egress proxy dengan allowlist per tenant. Hook `http` ke event gateway lewat jalur internal yang sama.
- **Rahasia tidak pernah jadi teks.** API key dan token git ada di vault, masuk ke env saat klaim, dicabut saat reclaim. Tidak masuk prompt, transkrip atau log.
- **Izin eksplisit.** `canUseTool` + mode izin per tenant; deny rules untuk perintah berbahaya (`rm -rf /`, akses metadata cloud).
- **Audit.** `PreToolUse` / `PostToolUse` dan setiap keputusan izin tercatat di audit log dengan `session_id` dan pengguna.
- **Lisensi dan autentikasi.** Produk yang melayani pengguna lain wajib memakai API key (Claude Console, Bedrock, Vertex) di bawah Commercial Terms. Login Free/Pro/Max tidak boleh dipakai atas nama pengguna; binary Claude Code tidak dimodifikasi.

#![arian] cat ./08_data-dan-penyimpanan.md

# Data dan penyimpanan

| DATA | DISIMPAN DI | CATATAN |
|---|---|---|
| **Event log sesi** | Storage service | Dari stream-json / SDK: pesan, tool call, hasil, biaya. Sumber kebenaran untuk tampilan chat dan resume. |
| **Transkrip agen** | Sandbox → storage | Dipulihkan lewat `SessionStore` saat resume di host lain. Format internal, jangan di-parse. |
| **Workspace** | Git host + snapshot | Commit per giliran atau per tugas; snapshot tar untuk resume cepat. |
| **Artefak** | Storage service | Build output, laporan, SVG diagram dari flowmaid. |
| **Rahasia** | Secret vault | Tidak pernah ditulis ke storage biasa. |
| **Metering** | Billing / account | Token dan biaya per `ResultMessage`, dijumlah per sesi dan tenant. |

#![arian] cat ./09_skala-dan-biaya.md

# Skala dan biaya

- **Ukuran awal.** 1 vCPU / 1 GiB per agen (titik awal dari dokumentasi hosting Agent SDK); naikkan per tenant untuk build berat.
- **Warm pool.** Jumlah pod hangat mengikuti puncak sesi baru per menit; target klaim di bawah 2 detik.
- **Idle dan TTL.** Suspend setelah idle beberapa menit; reclaim setelah TTL. Sesi tetap bisa dilanjutkan dari storage.
- **Biaya token.** Prompt caching otomatis menurunkan biaya konteks berulang. Kuota dan batas biaya per akun dicek orchestrator sebelum setiap giliran.
- **Observability.** OpenTelemetry dari SDK: latensi giliran, token, tool call, kegagalan.

#![arian] cat ./10_rencana-bertahap.md

# Rencana bertahap

| | |
|---|---|
| P0 | **`Proof of concept`** — satu container, Agent SDK, prompt dari chat dan token di-stream balik ke satu thread.<br>`selesai bila: satu pengguna internal bisa vibe coding end to end` |
| P1 | **`Sesi dan izin`** — session orchestrator, `resume`, kartu izin `canUseTool`, event log di storage service.<br>`selesai bila: sesi bertahan setelah container di-restart` |
| P2 | **`Notifikasi dan background`** — hook `http`, event gateway, notif service, ringkasan email.<br>`selesai bila: tugas 20 menit selesai dan pengguna dapat push` |
| P3 | **`Isolasi dan pool`** — sandbox per sesi, warm pool, egress proxy, vault, NetworkPolicy dan ResourceQuota per tenant.<br>`selesai bila: uji penetrasi antar tenant lulus` |
| P4 | **`flowmaid interaktif`** — WASM di klien, drag dan simpan via `to_mermaid`, SVG server-side untuk notif dan email.<br>`selesai bila: diagram dari agen bisa diedit dan dibaca balik oleh agen` |

#![arian] cat ./11_risiko.md

# Risiko dan pertanyaan terbuka

| RISIKO | MITIGASI |
|---|---|
| **Biaya token melonjak** | Batas biaya per akun dan per sesi; peringatan di chat sebelum batas; model lebih ringan untuk tugas rutin. |
| **Kode agen keluar sandbox** | Runtime terisolasi, deny-all network, tanpa kredensial cloud di env, egress proxy. |
| **Format internal berubah** | Pakai SDK dan stream-json saja; pin versi SDK dan CLI di image; uji upgrade di staging. |
| **Container mati di tengah tugas** | Event log + snapshot workspace; resume otomatis di sandbox baru. |
| **Kepatuhan lisensi** | API key per tenant atau milik pengguna; tidak ada login consumer bersama. |

- Bahasa orchestrator: Go (selaras dengan layanan yang ada) memanggil SDK TypeScript lewat sidecar, atau langsung `claude -p` stream-json?
- Kunci API: kunci platform dengan metering, atau bring-your-own-key per pengguna, atau keduanya?
- Hosted alternatif: Managed Agents (beta) dengan sandbox milik sendiri, untuk mengurangi kode orchestrator?

#![arian] cat ./12_referensi.md

# Referensi


- Agent SDK overview — code.claude.com/docs/en/agent-sdk/overview
- Agent SDK sessions · streaming · permissions · hosting — code.claude.com/docs/en/agent-sdk/
- Headless / `claude -p` — code.claude.com/docs/en/headless
- Hooks reference — code.claude.com/docs/en/hooks
- Managed Agents (beta) — platform.claude.com/docs/en/managed-agents/overview
- Legal and compliance — code.claude.com/docs/en/legal-and-compliance
- flowmaid — github.com/go-routine-id/flowmaid


LANGKAH BERIKUTNYA

# Siap untuk P0.

Satu container, satu thread chat, satu pengguna internal — lalu naik bertahap ke P4.